AI-103 — Manual Completo de Estudo

Developing AI Apps and Agents on Azure

Série oficial Microsoft Learn + AI-103 Study Cram de John Savill + consolidação para exame

Preparado para Gustavo Monteiro • Outubro de 2026

Como usar este manual

Este manual foi desenhado para ser lido como uma revisão final antes do exame AI-103. Não é uma transcrição dos vídeos: reorganiza o conteúdo por conceitos, relações e decisões arquiteturais, mantendo a cobertura do blueprint oficial do exame e dos tópicos confirmados na série e no study cram.

Nota de rigor — A série oficial é apresentada pela Microsoft como uma série de 26 episódios. Durante a compilação, 25 títulos individuais estavam publicamente indexados e o episódio 20 confirma explicitamente “Episode 20 of 26”. O título isolado do episódio 26 não estava indexado de forma fiável; por isso, este manual não inventa um título. A cobertura do syllabus oficial é, ainda assim, completa. O segundo vídeo fornecido pelo utilizador é incluído como fonte complementar, mas o seu transcript/metadata não estava publicamente acessível de forma fiável; só são integrados conceitos que também são suportados pelo syllabus oficial ou pelo study cram indexado.

1. O que o exame AI-103 mede

O AI-103 valida a capacidade de desenhar, desenvolver, implementar, proteger e operar aplicações e agentes de IA em Microsoft Foundry, com Python, APIs/SDKs e serviços Azure. O exame tem 120 minutos e pode incluir componentes interativos.

Domínio	Peso
Plan and manage an Azure AI solution	25–30%
Implement generative AI and agentic solutions	30–35%
Implement computer vision solutions	10–15%
Implement text analysis solutions	10–15%
Implement information extraction solutions	10–15%

Leitura estratégica — Mais de metade do exame está em planeamento/gestão + GenAI/agents. Mas Vision, Text/Speech e Information Extraction somam 30–45%; não devem ser tratados como “extras”.

2. O mapa mental que liga tudo

Pensa no AI-103 como uma pilha de camadas:

1. Infraestrutura e projeto Foundry: recursos, projetos, identidade, rede, quotas, deployments e CI/CD.
2. Modelos: LLMs, SLMs, multimodais, modelos de código e serviços especializados.
3. Dados e grounding: Azure AI Search, embeddings, vector/hybrid/semantic search, knowledge e Content Understanding.
4. Aplicação: SDKs/APIs, Responses API, Chat Completions, structured outputs, prompting e tools.
5. Agents: instructions + model + tools + knowledge + state/memory + policy.
6. Orquestração: Agent Framework, workflows, multi-agent, routing, handoff, HITL, checkpoints.
7. Serviços especializados: Language, Speech, Translator, Vision, image/video generation, Content Understanding.
8. Operação: evaluation, tracing, monitoring, guardrails, Responsible AI, custos e governance.

Fórmula mental — Modelo + instruções + ferramentas + conhecimento + estado = agente. Workflow =

controlo explícito sobre a sequência. RAG = recuperar evidência antes de gerar. MCP = contrato/padrão para expor ferramentas e contexto a agentes.

3. Série oficial Microsoft Learn — episódio a episódio

Episódio 1 — Plan and prepare to develop AI solutions on Azure

O que tens de saber

- Ecossistema Microsoft Foundry: resource, project, model catalog, deployments, playgrounds, tools e SDKs.
- Planeamento de requisitos: modalidade, latência, custo, segurança, dados, regiões e quotas.
- Responsible AI desde o desenho: segurança, privacidade, fairness, accountability, transparency e human oversight.
- Autenticação: preferir Microsoft Entra ID, managed identity e keyless credentials em produção.

Como se relaciona com o resto: É a fundação arquitetural. Liga-se a todos os episódios seguintes porque define onde vivem modelos, agents, ferramentas, knowledge e avaliações.

Armadilhas de exame: Confundir resource com project. • Escolher serviço/modelo sem considerar região, quota, custo ou modalidade. • Usar API keys quando existe managed identity/keyless auth.

Episódio 2 — Select, deploy, and evaluate Microsoft Foundry models

O que tens de saber

- Escolha entre LLM, SLM, code model e multimodal consoante tarefa, custo, qualidade, latência e contexto.
- Deployment é uma configuração operacional separada do modelo: nome, capacidade, versão, região e quotas.
- Model routing pode selecionar dinamicamente um modelo adequado; deve ser testado e avaliado.
- Evaluation: qualidade, groundedness, relevance, safety, latency e custo; comparar modelos com datasets representativos.

Como se relaciona com o resto: Liga model choice à operação. O mesmo app/agent pode trocar ou rotear modelos sem alterar toda a arquitetura.

Armadilhas de exame: “Maior modelo é sempre melhor” é falso. • Deployment e model catalog não são a mesma coisa. • Avaliação não é só accuracy: safety, grounding, latency e custo também importam.

Episódio 3 — Develop a generative AI chat app with Microsoft Foundry

O que tens de saber

- Conectar uma app ao projeto Foundry por SDK/API.
- Separar configuração/segredos do código.
- Gerir mensagens, contexto, instruções e parâmetros de geração.
- Usar outputs estruturados quando a aplicação precisa de dados previsíveis.

Como se relaciona com o resto: É a ponte entre portal e código: o Foundry prepara recursos; a app consome-os via SDK/API.

Armadilhas de exame: Hardcode de endpoints/keys. • Assumir que uma conversa longa deve ser enviada integralmente sem gestão de contexto. • Usar texto livre quando a app exige JSON/schema.

Episódio 4 — Develop generative AI apps that use tools

O que tens de saber

- Tool/function calling permite ao modelo pedir uma ação externa; o código executa a função e devolve o resultado.
- A definição da tool deve ter nome, descrição, schema de parâmetros e validação.
- Tools podem ser APIs, código, pesquisa, databases, MCP servers ou outros agents.
- Controlar permissões, timeout, retries e validação de outputs.

Como se relaciona com o resto: Transforma um chat em aplicação agentic: o modelo deixa de apenas responder e passa a poder agir.

Armadilhas de exame: Dar permissões excessivas à tool. • Confundir "modelo decidiu chamar" com "API foi executada pelo modelo". • Não validar argumentos produzidos pelo LLM.

Episódio 5 — Optimize generative AI model performance with Microsoft Foundry

O que tens de saber

- Prompt engineering: instruções claras, contexto, exemplos, formato de saída e restrições.
- Ajustar parâmetros de geração consoante estabilidade vs diversidade.
- Comparar prompting, RAG e fine-tuning/adaptation conforme problema.
- Medir resultados com evaluators em vez de otimizar por impressão subjetiva.

Como se relaciona com o resto: Liga prompting, model selection e evaluation num ciclo iterativo: medir → ajustar → medir novamente.

Armadilhas de exame: Otimizar sem benchmark. • Fine-tuning para resolver um problema que RAG ou prompting resolvem melhor. • Alterar parâmetros sem compreender impacto em consistência/custo.

Episódio 6 — Implement a responsible generative AI solution in Microsoft Foundry

O que tens de saber

- Content filters, safety systems, guardrails e risk detection.
- Red teaming e safety evaluations.
- Auditing: tracing, provenance, approvals e logging.
- Governança de tools: allowlists, scopes, human approval e limites de autonomia.

Como se relaciona com o resto: Responsible AI deixa de ser teoria e passa a controlos técnicos e operacionais.

Armadilhas de exame: Tratar content filter como substituto de governance. • Ignorar prompt injection/indirect prompt injection. • Não manter audit trail para ações sensíveis.

Episódio 7 — Develop AI agents with Microsoft Foundry and Visual Studio Code

O que tens de saber

- Agent = modelo + instructions + tools + knowledge + conversation/state.
- Criar/consumir agents por SDK em VS Code.
- Distinguir prompt agent e hosted/custom agent conforme controlo necessário.
- Definir role, goal, tool schemas e abordagem de conversation tracking.

Como se relaciona com o resto: É o ponto onde as peças anteriores se juntam num agente operacional.

Armadilhas de exame: Criar agent para qualquer tarefa quando uma chamada simples basta. • Confundir agent state com knowledge base. • Não limitar tool access.

Episódio 8 — Integrate custom tools into your agent

O que tens de saber

- Expor funções/APIs como tools com schema claro.
- Executar lógica determinística fora do LLM quando a ordem deve ser garantida.
- Validar inputs/outputs e tratar erros.
- Usar approval/HITL para ações de risco.

Como se relaciona com o resto: Permite arquiteturas híbridas: Agent → código determinístico/API → Agent.

Armadilhas de exame: Forçar tudo a ser "agentic". • Deixar o LLM executar lógica crítica que deveria ser código determinístico. • Não tratar falhas de tool.

Episódio 9 — Integrate MCP tools with Azure AI agents

O que tens de saber

- MCP (Model Context Protocol) padroniza como agentes descobrem e usam ferramentas/recursos.
- Um MCP server expõe capabilities; o agent/client decide quando e como usar.
- MCP reduz integrações proprietárias repetidas e facilita reutilização de tools.
- Autenticação e autorização continuam necessárias; MCP não elimina security boundaries.

Como se relaciona com o resto: MCP é uma forma de disponibilizar ferramentas ao agent, não um substituto do workflow ou da API subjacente.

Armadilhas de exame: Confundir MCP com o próprio agente. • Achar que MCP executa raciocínio. • Expor tools sensíveis sem scopes/approval.

Episódio 10 — Build knowledge-enhanced AI agents with Foundry IQ

O que tens de saber

- Adicionar knowledge/grounding ao agent para responder com informação atual ou privada.
- Separar memória de conversa de conhecimento empresarial.
- Recuperar evidência relevante antes da geração.
- Avaliar groundedness e qualidade da retrieval.

Como se relaciona com o resto: É a ligação entre agent + RAG/knowledge. O agent usa conhecimento como uma capability, em vez de confiar apenas no treino do modelo.

Armadilhas de exame: Confundir memory com knowledge. • Indexar conteúdo sem estratégia de chunking/metadata. • Não medir relevance/groundedness.

Episódio 11 — Integrate your agent with Microsoft 365

O que tens de saber

- Ligar agents a dados e ações Microsoft 365 com identidade e permissões adequadas.
- Trabalhar com dados empresariais respeitando scopes, RBAC e governance.
- Usar connectors/APIs/tools para SharePoint, mail, calendar ou outros serviços conforme cenário.
- Aplicar least privilege e distinguir read vs write actions.

Como se relaciona com o resto: Expande o agent para o ecossistema empresarial; é onde identity e governance ficam críticas.

Armadilhas de exame: Usar credenciais de utilizador de forma insegura. • Conceder permissões globais quando bastam scopes mínimos. • Não separar dados de tenants/identidades.

Episódio 12 — Build agent-driven workflows using Microsoft Foundry

O que tens de saber

- Workflow = sequência/orquestração explícita de passos, agents, executors e eventos.
- Combinar etapas agentic e determinísticas.
- State, checkpoints e pause/resume tornam workflows duráveis.
- HITL pode pedir informação/aprovação e retomar depois.

Como se relaciona com o resto: É a tradução programática do padrão que o utilizador já conhece de Copilot Studio/Power Automate: tópicos, flows, agents, tools e estado.

Armadilhas de exame: Usar multi-agent quando um workflow simples chega. • Não persistir estado em processos longos. • Deixar o modelo decidir passos que têm de ser determinísticos.

Episódio 13 — Develop an AI agent with the Microsoft Agent Framework

O que tens de saber

- Agent Framework oferece abstrações para agents, sessions, tools e integração com providers.
- Pode abstrair APIs de inferência subjacentes; a app trabalha com agents/sessions em vez de gerir cada chamada diretamente.
- Permite combinar agent calls com código normal.
- Pensar em Agent Framework como camada de aplicação/orquestração, não como modelo.

Como se relaciona com o resto: Senta-se acima de Responses/Chat Completions e do provider/modelo.

Armadilhas de exame: Confundir framework com Foundry Agent Service. • Achar que usar Agent Framework obriga a chamar Responses API manualmente. • Misturar responsabilidade de provider, framework e workflow.

Episódio 14 — Orchestrate a multi-agent solution using the Microsoft Agent Framework

O que tens de saber

- Padrões: sequential, concurrent, handoff, group chat e coordenação/manager.
- Especializar agents por função reduz prompts gigantes, mas aumenta complexidade operacional.
- Partilhar state/context apenas quando necessário.
- Definir limites, timeouts, stop conditions e observability.

Como se relaciona com o resto: É o nível acima do agent único: vários agents cooperam através de uma política de orquestração.

Armadilhas de exame: Multi-agent por moda. • Sem stop condition/cost control. • Duplicar responsabilidades entre agents.

Episódio 15 — Analyze text with Azure Language in Foundry Tools

O que tens de saber

- Serviços especializados para language detection, NER, PII, sentiment e outras tarefas.
- Usar serviço especializado quando queres comportamento mais previsível/estruturado.

- PII detection/redaction é preferível a improvisar com um LLM geral em fluxos de compliance.
- Resultados podem alimentar agents/workflows como tools.

Como se relaciona com o resto: Mostra quando Foundry Tools são melhores do que pedir tudo ao LLM.

Armadilhas de exame: Confundir NER com PII. • Usar LLM geral para uma tarefa com serviço especializado robusto sem razão. • Não tratar códigos/offsets/entidades corretamente.

Episódio 16 — Develop a text analysis agent with the Azure Language MCP server

O que tens de saber

- Agent interpreta intenção; MCP expõe Azure Language como tool; serviço executa análise.
- Combina raciocínio flexível com operação especializada.
- Tool descriptions ajudam o agent a selecionar a capability adequada.
- Resultados estruturados podem ser validados antes de continuar o workflow.

Como se relaciona com o resto: Padrão: agent decide → MCP tool executa → agent/workflow usa resultado.

Armadilhas de exame: Pensar que MCP substitui Azure Language. • Não distinguir decisão do agent da execução da tool.

Episódio 17 — Develop a speech-capable generative AI application

O que tens de saber

- Speech-to-text converte áudio em texto; text-to-speech converte texto em áudio.
- Streaming reduz latência percebida.
- Áudio pode ser uma modalidade de entrada para modelos multimodais.
- Formatos, codecs, sample rates e limites importam na integração.

Como se relaciona com o resto: Abre a camada de voz para apps e agents.

Armadilhas de exame: Confundir transcription com translation. • Ignorar streaming em UX de voz. • Não tratar formato de áudio.

Episódio 18 — Create speech-enabled apps with Microsoft Foundry

O que tens de saber

- Azure Speech oferece recognizer, synthesizer, voices e configurações especializadas.
- Speech especializado é adequado para reconhecimento/síntese controlados.
- Custom speech pode adaptar domínio/acústica quando suportado.
- Separar pipeline STT/TTS clássico de voice-to-voice realtime.

Como se relaciona com o resto: É a alternativa especializada ao uso puramente generativo de áudio.

Armadilhas de exame: Escolher Voice Live para um simples batch transcription. • Usar pipeline manual quando um serviço realtime gerido resolve melhor.

Episódio 19 — Develop a speech agent with the Azure Speech MCP server

O que tens de saber

- Expor STT/TTS/speech capabilities ao agent via MCP.
- Agent chama a tool apenas quando a intenção exige voz.
- A resposta de tool volta ao workflow/agent para continuar.

- Aplicar autenticação, limites e tratamento de erros.

Como se relaciona com o resto: Repete o padrão MCP com outra modalidade.

Armadilhas de exame: Achar que a tool "pensa". • Misturar tool selection com execution.

Episódio 20 — Develop an Azure Speech Voice Live agent in Microsoft Foundry

O que tens de saber

- Voice Live oferece sessões bidirecionais de baixa latência para conversação de voz.
- Full-duplex, streaming, interruption handling, turn detection/VAD e voice selection.
- Evita ter de orquestrar manualmente STT → LLM → TTS em muitos cenários realtime.
- Integração via SDK/sessão em tempo real.

Como se relaciona com o resto: É o serviço certo quando o requisito é conversa natural em tempo real, com interrupções.

Armadilhas de exame: Escolher Voice Live para batch. • Ignorar VAD/turn-taking. • Não considerar latência e concorrência.

Episódio 21 — Translate text and speech with Microsoft Foundry Tools

O que tens de saber

- Translation muda idioma; transliteration muda sistema de escrita.
- Azure Translator para tradução previsível e especializada.
- Speech translation pode combinar reconhecimento, tradução e síntese.
- LLM translation é útil em fluxos contextuais, mas deve ser avaliada para consistência/terminologia.

Como se relaciona com o resto: Liga Language/Speech a aplicações globais e agents multimodais.

Armadilhas de exame: Confundir translation e transliteration. • Escolher LLM quando requisito é serviço de tradução previsível sem necessidade de reasoning.

Episódio 22 — Develop a vision-enabled generative AI application

O que tens de saber

- Modelos multimodais compreendem texto + imagens e podem raciocinar sobre evidência visual.
- Casos: captioning, Q&A visual, alt text, comparação de imagens e análise contextual.
- Controlar detalhe/qualidade para equilibrar tokens/custo/latência.
- Mitigar prompt injection indireta via texto embebido em imagens.

Como se relaciona com o resto: Vision multimodal = compreensão flexível; não é o mesmo que extração estruturada de Content Understanding.

Armadilhas de exame: Confundir compreender imagem com gerar imagem. • Ignorar segurança de conteúdo visual e prompt injection.

Episódio 23 — Generate images and video

O que tens de saber

- Text-to-image, image editing, inpainting/masks e prompt-driven modifications.
- Text-to-video, image-to-video e edição/remix conforme modelo suportado.
- Escolher modelo e controlos de geração conforme modalidade e tarefa.
- Aplicar filtros, watermark/policy e governance quando necessário.

Como se relaciona com o resto: É geração, enquanto episódio 22 é compreensão.

Armadilhas de exame: Confundir generation com analysis. • Não validar direitos/policy/unsafe content. • Assumir que todos os modelos suportam todas as operações.

Episódio 24 — Analyze images with Content Understanding

O que tens de saber

- Content Understanding transforma media não estruturado em dados estruturados.
- Analyzer + schema define os campos esperados.
- Pode extrair atributos, regiões, descrições e informação consistente para downstream.
- Single-task vs pro-mode pipelines conforme complexidade.

Como se relaciona com o resto: Ao contrário de multimodal chat, o objetivo principal é extração estruturada e repetível.

Armadilhas de exame: Usar LLM livre quando a aplicação exige schema. • Confundir OCR simples com multimodal understanding completo.

Episódio 25 — Analyze documents with Content Understanding

O que tens de saber

- Combina OCR, layout analysis, field extraction e multimodal understanding.
- Produz JSON/Markdown limpo para agents, RAG e workflows.
- Custom analyzers permitem schemas de domínio.
- Documentos podem ser ingeridos e depois indexados para grounding.

Como se relaciona com o resto: É o elo entre documentos empresariais, extração e RAG/agents.

Armadilhas de exame: Confundir Document Intelligence/OCR com Content Understanding end-to-end. • Não validar campos/grounding. • Usar chunking sem preservar estrutura do documento.

Episódio 26 — Fecho da série e integração dos conceitos (título não indexado de forma fiável)

O que tens de saber

- Rever a arquitetura completa: Foundry → models → apps → tools → knowledge → agents → workflows → specialized services → evaluation/security.
- Consolidar decisões “quando usar o quê”.
- Validar que consegues implementar cada bloco por SDK/API, não apenas reconhecê-lo no portal.
- Usar practice assessment/labs para identificar lacunas reais.

Como se relaciona com o resto: Serve aqui como capítulo de integração final, sem atribuir um título que não foi possível confirmar.

Armadilhas de exame: Memorizar nomes sem compreender trade-offs. • Estudar por serviços isolados sem perceber como se ligam.

4. Deep dive — Microsoft Foundry, resources, projects e deployments

- Foundry resource: fronteira Azure onde vivem capacidades, identidade, rede, quotas e integrações.

- Project: espaço lógico de trabalho para uma solução/equipa, com configurações e ligações aos recursos.
- Model catalog: onde descobres modelos disponíveis; model deployment: instância/configuração consumível pela app.
- Playgrounds: ambiente de experimentação; não substituem código, testes automatizados nem CI/CD.
- Quotas/rate limits: planeia throughput, retries/backoff, concorrência e custos.
- CI/CD: configura infraestrutura e deployments de forma repetível; separa dev/test/prod e segredos.

Pergunta típica — Se o requisito é "usar um modelo já disponível, expô-lo à aplicação e controlar quota/capacidade", pensa em model deployment; se é "organizar ativos, ligações e experiências de uma solução", pensa em project.

5. Deep dive — Models, deployment, routing e evaluation

Escolha	Quando	Trade-off	Exemplo de requisito
LLM	Raciocínio/geração geral	Qualidade vs custo/latência	Assistente complexo, código, análise
SLM	Tarefa mais estreita/baixo custo	Menor capacidade geral	Classificação/extração simples em escala
Multimodal	Texto + imagem/áudio	Tokens/custo e segurança multimodal	Q&A visual, áudio contextual
Foundry Tool	Tarefa especializada	Menos flexível, mais previsível	PII, translation, speech, extraction
Model router	Vários modelos por request	Complexidade e avaliação	Balancear custo/qualidade automaticamente

Evaluation deve responder a duas perguntas: "o modelo/app faz a tarefa?" e "faz de forma segura, grounded e operacionalmente aceitável?". Métricas relevantes incluem quality, relevance, groundedness, fabrication/hallucination rate, safety, latency, token usage e cost.

6. Deep dive — APIs e SDKs: Responses, Chat Completions e Foundry SDK

- Chat Completions: padrão clássico baseado em mensagens system/user/assistant.
- Responses API: interface moderna para respostas com tools, multimodalidade e fluxos agentic; pode simplificar novas aplicações.
- Foundry SDK: abstrações Azure/Foundry para projeto, agents, deployments e integrações.
- Microsoft Agent Framework: camada acima da inferência/provider para agents, sessions, tools e orchestration.
- Conversations/session state: contexto persistente não é o mesmo que knowledge/RAG.

Hierarquia mental — Agent Framework → provider/inference API (Responses ou Chat Completions, dependendo do client) → model. O framework abstrai detalhes; não tens de chamar manualmente todas as APIs subjacentes em cada cenário.

7. Deep dive — RAG, Azure AI Search e knowledge

1. Ingest: recolher documentos/media.
2. Extract/enrich: OCR, layout, Content Understanding ou skills.
3. Chunk: dividir preservando contexto e metadata.
4. Embed: converter chunks em vetores quando usas vector search.
5. Index: armazenar campos, metadata e vectors no Azure AI Search.
6. Retrieve: keyword, vector, semantic ou hybrid search.
7. Ground: fornecer evidência recuperada ao modelo/agent.
8. Generate: produzir resposta com base na evidência.
9. Evaluate: relevance, groundedness, citation/provenance e search health.

Search	Força	Quando usar
Keyword	Termos exatos	IDs, nomes, palavras-chave
Vector	Semântica	Perguntas semelhantes em significado
Semantic	Re-ranking/entendimento semântico	Melhorar relevância de resultados textuais
Hybrid	Combina lexical + vector	Default robusto em muitos RAGs empresariais

Memory vs Knowledge — Memory lembra contexto da interação/utilizador. Knowledge fornece factos/documentos externos para grounding. Não são sinónimos.

8. Deep dive — Agents, tools, MCP e Agent Framework

- Agent: entidade com role/goal/instructions, model, tools, knowledge e state/session.
- Tool: capability que o agent pode pedir; a execução é feita por código/serviço, não “magicamente” pelo LLM.
- MCP: contrato padronizado para expor tools/resources/context; não é um LLM nem um workflow.
- Prompt agent: mais declarativo/gerido; hosted/custom agent: mais controlo de runtime/orchestration.
- Agent Framework: framework de código para criar agents, sessions e workflows multi-step/multi-agent.

9. Deep dive — Workflows híbridos e human-in-the-loop

Um dos padrões mais importantes para o AI-103 é misturar raciocínio probabilístico com software determinístico. Exemplo:

Pipeline — Evento/HTTP → código determinístico (validar/preparar) → Agent A → API externa → validação/regras → Agent B → HITL/aprovação → persistência/SharePoint.

- Usa código para regras exatas, validações, ficheiros, cálculos, API calls e compliance obrigatório.
- Usa LLM/agent para interpretação, classificação semântica, reasoning e decisões com ambiguidade.
- Usa workflow quando a ordem deve ser explícita e auditável.
- Usa HITL quando uma ação precisa de aprovação ou input humano.

- Usa checkpoint/persisted state quando o processo pode parar e retomar mais tarde.

10. Deep dive — Orquestração multi-agent

Padrão	Ideia	Usa quando
Sequential	A → B → C	Etapas especializadas dependentes
Concurrent	A, B, C em paralelo	Tarefas independentes/latência
Handoff	Um agent transfere controlo	Especialistas por domínio
Group Chat	Agents dialogam num contexto comum	Debate/consenso controlado
Manager/Magentic	Coordenador escolhe especialistas	Problemas complexos e dinâmicos

Regra de ouro — Começa com uma chamada simples; sobe para agent; sobe para workflow/multi-agent apenas quando existe uma necessidade real de tools, estado, especialização ou controlo.

11. Deep dive — Responsible AI, segurança e governance

- Identity: Entra ID, managed identity, keyless credentials; evitar segredos estáticos.
- Authorization: RBAC, least privilege, scopes e separação de leitura/escrita.
- Network: private networking/private endpoints quando exigido.
- Content safety: filtros, moderation, risk detection e políticas multimodais.
- Prompt injection: tratar input e retrieved content como não confiável; limitar tool access e validar ações.
- Guardrails: regras de entrada/saída, tool policies, data boundaries, approvals e stop conditions.
- Auditing: tracing, provenance, logs, approval records e versioning.
- Evaluation: safety evaluators, red teaming e testes adversariais.
- Operational controls: quotas, rate limits, budgets, retries, monitoring e incident response.

12. Deep dive — Language, Speech e Translation

Serviço/conceito	Faz	Escolha típica
Azure Language	NER, PII, sentiment, language tasks	Extração/deteção previsível
Generative LLM	Reasoning e texto flexível	Resumo contextual, transformação complexa
Azure Speech	STT/TTS especializado	Reconhecimento/síntese controlados
Voice Live	Conversação voz realtime	Baixa latência, interrupções, turn-taking
Translator	Translation/transliteration	Tradução especializada e consistente
Speech MCP	Expõe speech como tool	Agent chama voz apenas quando precisa

13. Deep dive — Vision, image/video generation e Content Understanding

- Multimodal understanding: modelo interpreta imagem + texto e responde de forma flexível.
- Image/video generation: cria ou edita media; inclui inpainting, masks e reference media conforme modelo.
- Content Understanding: converte media/documentos em estrutura previsível usando analyzers e schemas.
- OCR/layout: componentes de extração; Content Understanding pode combiná-los com reasoning multimodal.
- Visual safety: unsafe content, watermark/policy e indirect prompt injection por texto na imagem.

Distinção essencial — Multimodal model = "entende e raciocina sobre o que vê". Content Understanding = "extrai, de forma estruturada, os campos que a aplicação definiu". Image generation = "cria/edita media".

14. John Savill AI-103 Study Cram — o que acrescenta

O study cram de John Savill funciona como uma segunda passagem transversal ao syllabus. Os capítulos publicamente indexados cobrem:

- Core AI terms e Responsible AI.
- Foundry resource/project, models e deployment options.
- Playgrounds, model routing e evaluations.
- APIs/SDKs; Responses API; Chat Completions; comparação entre OpenAI e Foundry SDK.
- Tools, Responses tools, Foundry services/tools, skills, toolbox e knowledge.
- Optimization, guardrails e visão end-to-end da solução.
- Microsoft Agent Framework, agents, workflows e "agent harness".
- Foundry Agent Service: prompt agent, hosted agent e publishing.
- Language, Speech, Translation e Vision.
- Image/video generation, metrics/monitoring e Azure Content Understanding.

Valor principal do cram — Ele ajuda a ver as relações entre peças que, na série oficial, aparecem em episódios separados. Para o exame, essa visão de arquitetura e trade-offs costuma ser mais importante do que memorizar cliques no portal.

15. Segundo vídeo de overview — como usá-lo

Link fornecido: https://youtu.be/nUIPbpVjOc4?is=X75dbjR7RI-Uqksl

O vídeo não estava publicamente indexado com transcript/metadata verificável durante a compilação deste manual. Por isso, este documento não atribui ao vídeo afirmações específicas que não possam ser confirmadas. Usa-o como terceira perspetiva: anota apenas conceitos novos, divergências face ao material oficial e temas onde ainda hesitas; valida sempre qualquer diferença contra o study guide oficial.

16. Decision matrix — “Que serviço escolho?”

Requisito	Primeira opção a considerar
Responder com dados privados/atuais	RAG + Azure AI Search / knowledge grounding
Encontrar semântica em documentos	Vector/hybrid search
Encontrar termo/ID exato	Keyword search
PII/NER/sentiment previsível	Azure Language
Tradução previsível	Azure Translator
Conversão voz-texto/texto-voz clássica	Azure Speech
Voice agent realtime com interrupções	Voice Live
Entender uma imagem de forma livre	Multimodal model
Extrair schema de imagem/documento	Content Understanding
Gerar/editar imagem ou vídeo	Generative image/video model
Agent precisa de capability externa	Tool/function ou MCP tool
Passos têm ordem obrigatória	Workflow determinístico/híbrido
Vários especialistas precisam cooperar	Multi-agent orchestration
Ação sensível precisa de aprovação	HITL + approval/checkpoint
Produção sem secrets estáticos	Managed identity / keyless auth

17. O que normalmente diferencia uma resposta certa de uma “quase certa”

- Preferir serviço especializado quando o requisito pede previsibilidade e existe Foundry Tool adequada.
- Preferir RAG quando o problema é conhecimento atual/privado; não “treinar” o modelo com factos que mudam.
- Preferir managed identity/keyless auth quando a pergunta fala em segurança de produção.
- Preferir workflow quando a ordem é obrigatória; tool-calling quando o modelo pode decidir dinamicamente.
- Preferir HITL para ações de risco ou aprovação, não apenas mais um agent.
- Escolher hybrid/vector/semantic search pelo requisito de retrieval, não por moda.
- Avaliar groundedness/relevance quando existe RAG; safety e tool behavior quando existe agent.
- Separar multimodal understanding, media generation e structured extraction.

18. Checklist final antes do exame

☐ Consigo explicar resource vs project vs deployment.

☐ Consigo escolher LLM vs SLM vs multimodal vs Foundry Tool.

☐ Consigo explicar Responses vs Chat Completions vs Agent Framework.

☐ Consigo desenhar RAG: ingest → chunk → embed → index → retrieve → ground → generate → evaluate.

☐ Consigo escolher keyword/vector/semantic/hybrid search.

☐ Consigo explicar tool calling e MCP sem confundir decisão com execução.

☐ Consigo desenhar um workflow híbrido com código determinístico + agents + HITL.
☐ Consigo distinguir prompt agent vs hosted/custom agent em termos de controlo.
☐ Consigo escolher padrão multi-agent adequado.
☐ Sei aplicar managed identity, RBAC, private networking e least privilege.
☐ Sei o que medir em evaluation/observability.
☐ Sei quando usar Language, Speech, Translator e Voice Live.
☐ Sei distinguir Vision multimodal, generation e Content Understanding.
☐ Sei explicar Responsible AI como controlos técnicos e operacionais, não só princípios.

19. Mini-casos de exame para consolidar

Caso 1: A empresa quer um chatbot que responda sobre políticas internas atualizadas diariamente.

Resposta mental: RAG + Azure AI Search/knowledge grounding; não confiar no conhecimento paramétrico do modelo.

Caso 2: Um agent pode criar uma transferência financeira, mas só após aprovação.

Resposta mental: Tool com permissões mínimas + workflow + HITL/approval antes da execução.

Caso 3: É preciso remover PII de milhares de documentos.

Resposta mental: Azure Language/PII ou pipeline especializado; validar/redigir determinísticamente.

Caso 4: O utilizador interrompe o agente de voz enquanto ele fala.

Resposta mental: Voice Live, com session realtime, VAD/turn-taking e interruption handling.

Caso 5: Extrair sempre invoice number, total e supplier de PDFs heterogéneos.

Resposta mental: Content Understanding analyzer/schema; depois validar e persistir campos.

Caso 6: O sistema deve obrigatoriamente chamar uma API depois do Agent A e antes do Agent B.

Resposta mental: Workflow explícito: Agent A → executor/API → validação → Agent B.

Caso 7: Pesquisa por “contratos semelhantes a este”, mesmo sem palavras iguais.

Resposta mental: Vector ou hybrid search; semantic re-ranking quando aplicável.

Caso 8: O agent precisa de uma tool reutilizável exposta por vários runtimes.

Resposta mental: MCP server/tool, com autenticação e autorização adequadas.

20. Fontes e materiais de revisão

Microsoft Learn — Course AI-103T00-A: Develop AI apps and agents on Azure
https://learn.microsoft.com/en-us/training/courses/ai-103t00
Microsoft Learn — AI-103 Study Guide
https://learn.microsoft.com/en-us/credentials/certifications/resources/study-guides/ai-103
Microsoft Learn — Certification / exam page
https://learn.microsoft.com/credentials/certifications/exams/ai-103/
Microsoft Learn — official YouTube series
https://aka.ms/AI-103onYouTube
John Savill — AI-103 Develop AI Apps and Agents on Azure Study Cram
https://www.youtube.com/watch?v=WK2BvjOYTCQ
John Savill study cram — indexed Microsoft/Xebia Tech Hub page
https://tech.hub.ms/azure/videos/ai-103-develop-ai-apps-and-agents-on-azure-study-cram

21. Arquitetura end-to-end de referência — como todas as peças se ligam

Esta secção transforma o syllabus numa arquitetura única. O objetivo é conseguires olhar para um cenário e perceber onde entra cada serviço, onde termina o raciocínio probabilístico e onde deve começar o controlo determinístico.

Mapa mental principal: Canal/Aplicação → Foundry Project → Modelo/Agent → Tools/Knowledge → Workflow → Serviços especializados → Validação/HITL → Observability/Security.

1. Entrada e identidade: utilizador, aplicação, ficheiro, evento ou API entram por um endpoint autenticado. Em produção, privilegia Microsoft Entra ID, managed identity e RBAC em vez de segredos estáticos.
2. Foundry Project: fornece o contexto do projeto, ligações a modelos/deployments, tools, knowledge e configurações de avaliação/segurança.
3. Inference ou Agent: uma chamada simples ao modelo resolve tarefas diretas; um agent é adequado quando é preciso decidir entre tools, conhecimento, memória ou múltiplas ações.
4. Grounding/RAG: se a resposta depende de dados privados, atuais ou volumosos, recupera evidência relevante e fornece-a ao modelo em vez de esperar que o modelo "saiba" os factos.
5. Workflow: quando a ordem dos passos é obrigatória, modela-a explicitamente. Ex.: Agent A → API → validação → Agent B → aprovação humana.
6. Foundry Tools/serviços especializados: Language, Speech, Translator, Content Understanding, Search e outros executam operações especializadas e previsíveis.
7. Validação: structured outputs, schemas, regras de negócio, retries, timeouts e verificações determinísticas protegem o fluxo contra outputs inválidos.
8. Human-in-the-loop: ações de risco, decisões irreversíveis ou exceções podem pausar o workflow e esperar por aprovação/input humano.
9. Operação: tracing, avaliações, logs, custos, safety signals, grounding quality e métricas de latência devem acompanhar a solução em produção.

22. O grande mapa de decisões — quando usar o quê

Requisito	Escolha provável	Porquê
Pergunta simples sobre conhecimento geral	Chamada direta a um modelo	Evita criar agent/workflow sem necessidade.
Resposta baseada em documentos internos/atuais	RAG + Azure AI Search/knowledge	O conhecimento muda; não é um problema de fine-tuning.
Extrair PII, entidades ou sentimento de forma previsível	Azure Language / Foundry Tool	Serviço especializado, output estruturado e adequado a escala/compliance.
Extrair campos repetíveis de PDFs/imagens heterogéneos	Content Understanding analyzer + schema	Objetivo é estrutura previsível, não resposta livre.
Perguntar livremente sobre uma imagem	Modelo multimodal vision-enabled	Compreensão flexível e reasoning visual.
Gerar/editar imagens ou vídeo	Modelo de generation adequado	Escolhe operação: text-to-image,

Requisito	Escolha provável	Porquê
		edit/inpaint, text/image-to-video.
Conversação de voz realtime com interrupções	Voice Live	Baixa latência, streaming, VAD/turn-taking e interruption handling.
STT/TTS simples ou batch	Azure Speech / speech APIs	Não precisas do runtime realtime completo.
Agent precisa de capability reutilizável	Tool/function ou MCP	MCP padroniza exposição/descoberta; tool continua a ser executada por um serviço/código.
Sequência obrigatória de passos	Workflow explícito	Developer controla a ordem.
Modelo pode decidir dinamicamente se usa uma API	Tool calling	Model decides; aplicação valida e executa.
Ação sensível exige aprovação	HITL / approval step	Não uses outro agent como substituto de aprovação humana.
Vários especialistas realmente necessários	Multi-agent orchestration	Só quando a especialização/coordenação compensa complexidade e custo.
Regras de negócio exatas	Código determinístico	Não delegar cálculos/regras críticas a um LLM sem necessidade.

23. RAG e Azure AI Search — versão aprofundada

RAG é um pipeline, não apenas “ligar documentos ao chat”. Em perguntas de exame, identifica em que fase está o problema: ingestão, enriquecimento, indexação, retrieval, grounding ou evaluation.

- Ingestão: recolher conteúdo de Blob, SharePoint, bases de dados, APIs, documentos e media.
- Extração/enrichment: OCR, layout, Content Understanding e skills podem transformar conteúdo bruto antes da indexação.
- Chunking: dividir conteúdo em unidades recuperáveis. Chunks demasiado pequenos perdem contexto; demasiado grandes reduzem precisão e aumentam tokens.
- Metadata: guarda source, document ID, timestamp, ACL, section/title e outros filtros úteis. Metadata é crítica para security trimming e filters.
- Embeddings: representação vetorial usada para semelhança semântica. Não substitui o conteúdo original nem a metadata.
- Index: define campos pesquisáveis, filtráveis, ordenáveis e vetoriais conforme o cenário.
- Retrieval keyword: excelente quando termos exatos importam.
- Vector search: encontra semelhança semântica mesmo com vocabulário diferente.
- Hybrid search: combina lexical + vector; frequentemente é uma base forte para RAG empresarial.
- Semantic ranking: pode reordenar resultados com compreensão semântica para melhorar relevance.

- Grounding: os resultados recuperados são contexto/evidência; o prompt deve instruir o modelo a responder com base neles.
- Citações/provenance: quando o cenário pede auditabilidade, preserva origem e referências dos chunks.
- Evaluation: mede retrieval relevance e groundedness separadamente. Uma resposta má pode vir de retrieval má mesmo que o modelo seja bom.

Diagnóstico rápido: "não encontrou o documento certo" = retrieval/index problem. "Encontrou a evidência certa mas inventou" = generation/grounding/prompt/safety problem.

24. Agents, tools e MCP — modelo mental completo

Conceito	Responsabilidade	Não confundir com
Modelo	Gerar/raciocinar sobre input	Agent completo
Agent	Modelo + instructions + tools + knowledge + state/policy	Workflow determinístico
Tool/function	Capacidade externa que pode ser solicitada	O LLM executar a ação diretamente
MCP server	Expor tools/resources através de protocolo padronizado	Modelo, agent ou workflow
Session/conversation	Estado/contexto de interação	Knowledge base/RAG
Knowledge	Dados externos usados para grounding	Memória de conversa
Workflow	Orquestração explícita de passos/eventos	Tool calling dinâmico
Checkpoint	Snapshot para retomar/replay de workflow	Uma nova conversa
HITL	Pedido/approval externo e retoma	Outro agent "humano"

Tool calling — ciclo lógico

10. O modelo recebe instructions, contexto e descrição das tools.
11. O modelo decide que precisa de uma tool e produz argumentos estruturados.
12. A aplicação valida os argumentos e a autorização.
13. O código/serviço executa a tool.
14. O resultado da tool volta ao modelo/agent ou ao workflow.
15. O modelo continua o reasoning ou produz resposta final.

Ponto de exame: o modelo não "executa a API". Ele pede a chamada; a aplicação/tool runtime executa-a.

25. Agent Framework — como pensar em código

O Microsoft Agent Framework deve ser visto como uma camada de programação para agents, sessions, tools e workflows. Não é um modelo e não elimina o provider de inferência.

Quando	Padrão
Um agent e algumas tools chegam	Agent simples + session/state
A ordem tem de ser garantida	Workflow explícito com executors/steps
Passos independentes podem correr juntos	Concurrent/parallel orchestration
Um especialista transfere controlo	Handoff
Vários agents colaboram numa conversa	Group chat
Um coordenador escolhe especialistas	Manager/Magentic-like orchestration
Processo longo precisa parar/retomar	Checkpoint + persisted state
Precisa de aprovação/input externo	Request/HITL + resume

Pseudocódigo mental — workflow híbrido

```
input_file = download_from_sharepoint()
validated = validate_and_reduce(input_file)
order = await agent_a.run(validated)
output_file = apply_order_deterministically(input_file, order)
assert validate_output(output_file)
api_result = call_business_api(output_file)
summary = await agent_b.run(api_result)
approval = await request_human_approval(summary)
if approval:
    upload_to_sharepoint(output_file)
```

Este padrão é exatamente o que o exame quer que saibas arquitetar: reasoning onde existe ambiguidade; código onde existe uma regra exata.

26. Segurança e threat model para soluções agentic

Risco	Mitigação típica
Secrets leakage	Managed identity/keyless auth; Key Vault quando segredo é inevitável; nunca hardcode.
Excesso de permissões	RBAC, scopes mínimos, separar read/write e ambientes.
Prompt injection direto	Tratar user input como não confiável; instructions robustas; policy/guardrails.
Indirect prompt injection	Conteúdo recuperado, documentos, webpages e imagens também são input não confiável.
Tool abuse	Allowlist, schema validation, authorization,

Risco	Mitigação típica
	approval para ações sensíveis, rate limits.
Data exfiltration	Private networking, data boundaries, ACL/security trimming, egress control quando aplicável.
Hallucinated actions	Structured output + deterministic validation antes de executar.
Runaway agents/cost	Budgets, token/tool limits, stop conditions, timeouts, max iterations.
Untraceable decisions	Tracing, provenance, correlation IDs, audit logs e approval records.
Unsafe multimodal content	Content filters/policy, visual safety e deteção de prompt injection em media.

27. Evaluation e observability — o que medir em cada camada

Camada	Métricas/observações
Modelo/app generativa	Quality, relevance, fabrication/hallucination, safety, latency, token/cost.
RAG retrieval	Recall/relevance, top-k usefulness, index health, freshness, filters/ACL.
Resposta grounded	Groundedness, citation/provenance, answer relevance.
Agent	Task success, tool selection, tool-call accuracy, loops, autonomy violations, safety.
Workflow	Step failures, retries, checkpoint/resume, SLA, human wait time, end-to-end latency.
Speech/voice	Latency, recognition quality, interruption/turn handling, synthesis quality.
Content Understanding	Field accuracy/completeness, schema validity, extraction confidence, downstream errors.
Produção	Drift, safety events, quotas, scaling, rate limits, cost footprint, incidents.

Evaluation offline diz se a solução está pronta; observability online diz se continua saudável em produção.

28. Services especializados — diferenças que costumam confundir

A	B	Diferença decisiva
Azure Language PII/NER	LLM geral	Language é especializado/previsível; LLM é flexível e contextual.
Translator	LLM translation	Translator é serviço especializado; LLM é útil quando contexto/style/reasoning acrescenta valor.
Speech STT/TTS	Voice Live	Speech clássico para reconhecimento/síntese; Voice Live para conversa realtime bidirecional.
Vision multimodal	Content Understanding	Vision responde/raciocina livremente; CU extrai estrutura/analyzer/schema.
OCR/layout	Content Understanding	OCR/layout são componentes de extração; CU combina extração e entendimento multimodal em output estruturado.
Image understanding	Image generation	Um analisa media existente; o outro cria/edita media.
RAG	Fine-tuning	RAG fornece factos externos/atuais; fine-tuning altera comportamento/padrões, não é base de conhecimento dinâmica.
Session memory	RAG knowledge	Session mantém contexto de interação; RAG recupera conhecimento externo.
Tool calling	Workflow	Tool calling pode ser decidido pelo modelo; workflow impõe sequência/control flow.
Function tool	MCP tool	Função é integração específica; MCP é protocolo padronizado para expor/discover capabilities.

29. Como ler perguntas de exame por palavras-chave

- “private/current enterprise data”, “grounded answers”, “citations” → pensa em RAG/knowledge/Azure AI Search.

- “similar meaning even if different words” → vector search; se também queres termos exatos, considera hybrid.
- “structured/repeatable fields from documents/images” → Content Understanding/analyzer/schema.
- “real-time voice”, “interruptions”, “natural conversation” → Voice Live.
- “least privilege”, “no keys”, “production security” → managed identity, RBAC, keyless credentials.
- “must always happen after/before” → workflow explícito / deterministic step.
- “agent chooses when needed” → tool/function calling.
- “reusable external tools across clients/runtimes” → MCP.
- “approval required before action” → HITL / approval workflow.
- “untrusted content in retrieved docs/images” → indirect prompt injection mitigation.
- “why answer is wrong despite good model” → investiga retrieval quality, grounding e prompt/evaluation, não assumes logo trocar de modelo.
- “cost/latency constraints” → SLM/appropriate model, routing, quotas, caching/batching quando aplicável, medir trade-offs.

30. Blueprint oficial — checklist completa por domínio

Usa esta lista para garantir cobertura contra o Study Guide oficial (competências medidas desde 16/04/2026).

Plan and manage an Azure AI solution (25–30%)

- ☐ Escolher LLM, SLM, multimodal model ou Foundry Tool conforme tarefa.
- ☐ Escolher serviços para generation, grounding, vector search, workflows e multimodal.
- ☐ Escolher retrieval/indexing e memory/tool/knowledge integration.
- ☐ Desenhar infraestrutura, deployment options, model/agent deployments e CI/CD.
- ☐ Gerir quotas, scaling, rate limits e custos.
- ☐ Monitorizar model performance, drift, safety, grounding, ingestion e search index health.
- ☐ Configurar managed identity, private networking, keyless credentials e role policies.
- ☐ Configurar filters, guardrails, risk detection, moderation, evaluators, auditing e tool-access controls.

Generative AI and agentic solutions (30–35%)

- ☐ Deploy/consume LLMs, small/code/multimodal models.
- ☐ Implementar RAG, multistep/tool-augmented workflows e Foundry SDK/connectors.
- ☐ Avaliar fabrication, relevance, quality e safety.
- ☐ Definir role/goal/conversation tracking/tool schemas.
- ☐ Integrar retrieval, function calling, memory, APIs, knowledge stores, search, Content Understanding e custom functions.
- ☐ Implementar multi-agent e autonomous/semiautonomous workflows com safeguards/approval.
- ☐ Observability, error analysis, prompt/model parameter tuning.
- ☐ Reflection/self-critique evaluation e hybrid LLM + rules engines.

Computer vision (10–15%)

- ☐ Image/video generation com text/reference media; editing, masks/inpainting e video edits.
- ☐ Multimodal visual context, captions, visual Q&A, alt text e extended descriptions.
- ☐ Content Understanding para visual characteristics, video segments, single-task/pro mode e regions/objects.
- ☐ Visual safety, indirect prompt injection, watermarks/brand policy/unsafe symbols.

Text analysis (10–15%)

- ☐ Entities, topics, summaries, structured JSON, sentiment/tone/safety/sensitive content.
- ☐ Translator ou LLM-powered translation e domain-specific text tasks.
- ☐ Speech-to-text, text-to-speech, custom speech, audio reasoning e speech translation.

Information extraction (10–15%)

- ☐ Ingest/index documents, images, audio e video.
- ☐ Semantic/hybrid/vector search e enrichment skills.
- ☐ RAG ingestion com OCR e ligação direta a workflows/agent tools.
- ☐ Multimodal document extraction: OCR + layout + fields.
- ☐ Content Understanding para representations limpas/grounded e analyzers structured/markdown.

31. Capstone AI-103 — projeto único que consolida o syllabus

O projeto não precisa de estar concluído antes do exame, mas é uma excelente forma de converter estudo em experiência prática. Uma arquitetura coerente é melhor do que 26 demos desconectadas.

Módulo do projeto	Features AI-103 demonstradas
Ingestão empresarial	SharePoint/Blob/API; auth; download; metadata; logging.
Document pipeline	Content Understanding/OCR/layout → schema/Markdown → validação.
Knowledge/RAG	Chunking, embeddings, Azure AI Search, hybrid/vector/semantic, citations.
Agent principal	Instructions, tools, knowledge, structured outputs, session/state.
MCP	Uma capability externa exposta por MCP server e consumida pelo agent.
Workflow híbrido	Agent → deterministic code/API → validation → Agent → HITL → resume.
Multi-agent	Especialistas só onde fizer sentido; handoff/manager/sequential/concurrent.
Language	PII/NER/sentiment ou outra análise especializada.
Speech	STT/TTS e, se justificável, uma demo Voice Live.
Translation	Texto/voz com Translator ou tool especializada.
Vision	Multimodal Q&A sobre imagem + alt text/accessibility.
Generation	Imagem e opcionalmente vídeo, com safety/policy.
Operations	Evaluation datasets, tracing, safety, latency, token/cost metrics e monitoring.
Security	Managed identity/RBAC, least privilege, secrets, network/data boundaries.

Módulo do projeto	Features AI-103 demonstradas
README/architecture	Diagrama, trade-offs, custos, failure modes, testing e decisões “why”.

32. Revisão de 15 minutos — folha mental final

- Foundry organiza projeto, modelos, agents, tools, knowledge, evaluation e segurança.
- Deployment ≠ model; project ≠ resource.
- RAG: ingest → extract/enrich → chunk → embed → index → retrieve → ground → generate → evaluate.
- Agent = model + instructions + tools + knowledge + state/policy.
- Tool calling: modelo pede; aplicação valida/executa; resultado regressa.
- MCP = protocolo para expor/discover tools/resources; não é agent nem workflow.
- Workflow = developer controla sequência; tool calling = modelo pode decidir.
- Agent Framework = camada de código para agents/sessions/tools/workflows.
- HITL = pausa externa + resposta + resume; checkpoint permite persistência/replay.
- Language para NLP especializado; Speech para STT/TTS; Voice Live para realtime voice; Translator para translation.
- Vision multimodal compreende; generation cria; Content Understanding estrutura/extrai.
- Managed identity + RBAC + least privilege + private networking + auditing são defaults de produção.
- Evaluation mede quality/relevance/groundedness/safety; observability acompanha tracing/latency/tokens/cost/safety em produção.
- Não transformes tudo em AI: regras exatas ficam em código determinístico.

33. Nota de atualização da versão expandida

Esta versão foi expandida com base no AI-103 Study Guide oficial da Microsoft (competências medidas desde 16 de abril de 2026), na série oficial já coberta no manual e nos tópicos verificados do John Savill Study Cram. O segundo vídeo fornecido pelo utilizador continua a ser usado como material complementar; como não foi possível obter transcript/metadata verificável por pesquisa pública, nenhum conteúdo exclusivo é atribuído a esse vídeo sem evidência. Quando terminares o vídeo, os pontos novos que identificares podem ser incorporados numa revisão seguinte.

34. Revisão de lacunas — pontos que faltavam aprofundar

Depois de comparar novamente o manual com o blueprint oficial do AI-103, a cobertura geral estava forte, mas havia alguns objetivos oficiais que apareciam apenas na checklist final ou de forma demasiado breve. Esta secção aprofunda esses pontos.

34.1 Reflection, self-critique e avaliações de reasoning

- Reflection/self-critique: o sistema pode produzir uma primeira resposta, avaliá-la segundo critérios definidos e tentar melhorar o resultado antes de o devolver.
- No exame, pensa nisto como um padrão de otimização/evaluation, não como substituto de grounding, validação ou regras de negócio.
- Uma segunda passagem do mesmo modelo não garante verdade. Se o problema é conhecimento privado/atual, continua a ser necessário RAG/grounding.
- Avaliações de reasoning devem medir a qualidade do processo e do resultado com critérios observáveis; em produção, evita depender de texto de raciocínio interno como mecanismo de auditoria.
- Quando o enunciado pedir uma combinação de raciocínio flexível com regras obrigatórias, pensa em hybrid LLM + rules engine.

34.2 Observability mais granular

- Tracing: correlaciona chamadas ao modelo, retrieval, tools, agents e workflow steps numa execução.
- Token analytics: acompanha input/output tokens, custo por chamada, por utilizador, por agent e por workflow.
- Latency breakdown: mede separadamente retrieval latency, model latency, tool/API latency e tempo total end-to-end.
- Safety signals: acompanha content filters, policy violations, blocked tool calls e eventos de guardrails.
- Agent error analysis: distingue erro de routing, tool selection, tool arguments, retrieval, grounding e geração final.
- Uma solução lenta não implica necessariamente trocar de modelo: primeiro identifica em que camada está a latência.

34.3 Multimodal vision — objetivos específicos do blueprint

- Visual Q&A: responder a perguntas com base em evidência contida numa ou mais imagens.
- Captions: gerar descrições concisas ou detalhadas; extended descriptions dão mais contexto.
- Alt text: produzir descrições adequadas a acessibilidade; o objetivo não é apenas descrever visualmente, mas tornar a informação útil a quem não vê a imagem.
- Video analysis: processar e interpretar segmentos de vídeo, e não apenas frames isolados.
- Regions/objects/components: identificar elementos ou regiões concretas dentro de imagens ou vídeo.
- Não confundir vision-enabled LLM com Content Understanding: o primeiro raciocina de forma flexível; o segundo cria extração estruturada e pipelines previsíveis.

34.4 Responsible AI para conteúdo multimodal

- Aplicar filtros para classificar conteúdo visual inseguro ou proibido.
- Indirect prompt injection: texto malicioso pode estar incorporado numa imagem/documento e tentar alterar o comportamento do agent; trata conteúdo recuperado como não confiável.
- Separar instruções de sistema das instruções encontradas nos dados e restringir tools/ações permitidas.
- Visual policy controls podem incluir watermarks, brand rules, deteção de símbolos proibidos e sinalização de conteúdo inadequado.

- Em ações de maior risco, acrescenta validação determinística e/ou human approval.

34.5 Speech — pontos que merecem ficar explícitos

- Custom Speech: adaptar reconhecimento de fala a vocabulário, domínio ou condições acústicas específicas quando o cenário o exigir.
- Audio multimodal reasoning: alguns modelos podem receber áudio como modalidade, permitindo raciocínio sobre o conteúdo sem reduzir mentalmente o problema apenas a STT tradicional.
- Speech translation: pode combinar reconhecimento, tradução e, se necessário, síntese na língua de destino.
- SpeechRecognizer/Synthesizer são componentes especializados; Voice Live é a opção mental para conversação bidirecional em tempo real, baixa latência, turn-taking e interrupções.

34.6 Information extraction e Content Understanding — detalhe adicional

- O pipeline pode ingerir documentos, imagens, áudio e vídeo; a extração não está limitada a PDFs.
- Enrichment skills podem transformar texto, imagem e layout antes da indexação/retrieval.
- OCR converte conteúdo visual em texto; layout analysis preserva estrutura; field extraction transforma conteúdo em campos úteis.
- Content Understanding pode produzir outputs estruturados ou Markdown limpo para downstream reasoning, RAG e agents.
- Single-task e pro-mode devem ser reconhecidos como opções de pipeline/configuração no Content Understanding conforme a complexidade do cenário.
- A pergunta de exame pode testar a diferença entre extrair campos estruturados e simplesmente perguntar a um LLM multimodal sobre um documento.

35. Mecânica do exame — o que convém saber antes de marcar

- Pontuação mínima de aprovação: 700.
- Tempo indicado pela Microsoft para o AI-103: 120 minutos.
- O exame é proctored e pode incluir componentes interativos, não apenas perguntas de escolha múltipla.
- Usa o Exam Sandbox da Microsoft para conhecer a interface e os tipos de interação antes do exame.
- O exame está disponível em várias línguas; confirma a língua escolhida no momento do agendamento.
- A Microsoft recomenda agendar com uma conta Microsoft pessoal (MSA) para manter os registos de certificação independentes da entidade empregadora.

36. Prioridade final de estudo

Se o tempo for curto, não distribuas o esforço por igual. Prioriza primeiro Plan and manage + Generative AI/Agents, porque juntos representam aproximadamente 55–65% do blueprint. Depois garante que sabes escolher corretamente entre Vision, Text/Speech e Information Extraction.

- Prioridade 1: Foundry architecture, models/deployments, security, evaluation e Responsible AI.
- Prioridade 2: RAG/Search, agents, tools, MCP, Agent Framework, workflows, multi-agent e HITL.
- Prioridade 3: Vision/multimodal + image/video generation + visual safety.
- Prioridade 4: Language, Speech, Translator e audio modalities.
- Prioridade 5: Content Understanding, OCR/layout, enrichment e structured extraction.

37. Fontes oficiais usadas nesta revisão

AI-103 Study Guide (skills measured as of 16 April 2026):

https://learn.microsoft.com/en-us/credentials/certifications/resources/study-guides/ai-103

AI-103 certification / exam page:

https://learn.microsoft.com/en-us/credentials/certifications/exams/ai-103/

AI-103 course:

https://learn.microsoft.com/en-us/training/courses/ai-103t00